



Clustering de pays pour l'optimisation de l'aide humanitaire

DecisionSupportSystem | DataScienceForGood | EvidenceBasedPolicy | HumanCenteredAI

Note de cadrage

Rédigé par l'équipe :
SigmaPulse



Pour l'ONG :
Help International



MAI 2026

QUI SOMMES-NOUS ?

Ce travail a été réalisé dans un cadre académique par l'équipe SigmaPulse, dont la démarche vise à combiner la précision mathématique (σ) et l'analyse des dynamiques d'urgence humanitaire (Pulse) afin de construire une approche d'aide à la décision fondée sur les données.

Dans un contexte mondial marqué par la multiplication des crises sanitaires, économiques, climatiques et sécuritaires, l'identification des pays prioritaires constitue un enjeu stratégique majeur pour les organisations humanitaires internationales. Le projet s'inscrit dans une collaboration académique inspirée du contexte opérationnel de l'ONG HELP International, confrontée à une contrainte budgétaire fictive de 10 millions de dollars destinée à soutenir les pays les plus vulnérables.

Notre ambition est d'exploiter les méthodes de Machine Learning non supervisé afin d'identifier des groupes homogènes de pays selon leurs vulnérabilités économiques, sanitaires, sociales et sécuritaires, dans une logique d'allocation plus rigoureuse, transparente et explicable des ressources humanitaires.

« L'aide humanitaire du futur ne peut plus reposer sur des intuitions géopolitiques ou des approximations décisionnelles. Avec une enveloppe limitée de 10 millions de dollars, chaque erreur de ciblage se traduit par des milliers de vies potentiellement non assistées. Notre ambition est d'exploiter le Machine Learning pour transformer des indicateurs macroéconomiques et sociaux complexes en une allocation de ressources rigoureuse, transparente et fondée sur les données. »

— ÉQUIPE SIGMAPULSE

CONTENU



1. Contexte et justification

2. Présentation du commanditaire : HELP International

3. Problématique

4. Objectifs du projet

5. Périmètre du projet

6. Approche méthodologique

7. Livrables

8. Limites et précautions

Perspectives

Sources

Conclusion

1. CONTEXTE ET JUSTIFICATION

1.1 Une crise humanitaire mondiale en expansion

Les besoins humanitaires mondiaux atteignent des niveaux sans précédent. Selon le Bureau de la coordination des affaires humanitaires des Nations Unies (OCHA), le nombre de personnes nécessitant une aide humanitaire a plus que doublé en dix ans, passant de 80 millions en 2014 à plus de 300 millions en 2024 (OCHA, Global Humanitarian Overview 2024). Cette progression est alimentée par la multiplication des conflits armés, l'intensification des catastrophes climatiques, et la persistance de vulnérabilités structurelles dans de nombreux pays à faible revenu.

Face à cette demande croissante, les ressources disponibles restent structurellement insuffisantes. En 2023, le financement humanitaire mondial a couvert moins de 40 % des besoins identifiés (OCHA, Financial Tracking Service, 2023). Dans ce contexte de pénurie, la qualité du ciblage devient un enjeu éthique et opérationnel de premier ordre : mal allouer des ressources rares, c'est priver d'assistance des populations qui en ont un besoin vital.

1.2 Du diagnostic qualitatif à la preuve quantitative

Historiquement, les décisions d'allocation reposent sur des indicateurs macro partiels (IDH, rapports annuels PNUD), des critères géopolitiques, ou des perceptions médiatiques des crises. Ces approches souffrent de trois biais majeurs : le biais de disponibilité (on intervient là où les crises sont visibles), le biais de confirmation (on aide les pays déjà identifiés comme fragiles), et l'inertie institutionnelle (les priorités changent lentement malgré l'évolution des contextes).

Face à ces limites, les institutions internationales encouragent désormais le recours aux approches data-driven pour améliorer la transparence et l'efficacité des interventions humanitaires. Le Comité international de la Croix-Rouge (CICR) ainsi que l'OCHA identifient la donnée et l'analytique comme des leviers stratégiques majeurs pour la décennie 2020–2030.

Dans cette perspective, les techniques de Machine Learning permettent :

- d'exploiter simultanément un grand nombre d'indicateurs ;
- de révéler des structures cachées dans les données ;
- d'identifier des profils de vulnérabilité similaires ;
- et de produire des segmentations objectivées des pays.

Le présent projet s'inscrit dans cette dynamique d'innovation analytique appliquée à l'aide humanitaire.

2. PRÉSENTATION DU COMMANDITAIRE



HELP — Hilfe zur Selbsthilfe — est une ONG humanitaire internationale fondée en 1981, dont le principe fondateur est « l'aide à l'auto-aide » : favoriser l'autonomie locale et la reconstruction durable plutôt que la dépendance à l'assistance extérieure.

HELP intervient dans les domaines suivants : aide d'urgence (conflits, tremblements de terre, tsunamis), reconstruction post-catastrophe, santé et nutrition, eau et assainissement (WASH), sécurité alimentaire, éducation et protection. En 2024, l'organisation a assisté 8,1 millions de personnes dans 31 pays via 104 projets, pour un budget total de 66,9 millions d'euros, dont 94,3 % alloués directement aux projets terrain (Rapport annuel HELP.NGO, 2024).

Dans le cadre du présent projet, HELP International dispose d'une enveloppe exceptionnelle de 10 millions de dollars destinée à cibler les pays les plus vulnérables parmi 167 éligibles. La contrainte budgétaire impose une priorisation rigoureuse : il est impossible d'intervenir partout avec la même intensité. Les décisions de ciblage doivent être objectivables, défendables devant les donateurs, et reproductibles dans le temps.

3. PROBLÉMATIQUE

Comment identifier, parmi 167 nations, celles qui présentent une vulnérabilité combinée — c'est-à-dire une conjonction de faiblesse structurelle économique et de détresse sanitaire et sécuritaire critique — en utilisant exclusivement des données objectives et reproductibles, afin d'orienter de manière éthique et efficiente une allocation budgétaire de 10 millions de dollars ?

4. OBJECTIFS DU PROJET

Objectif général

Construire un système de segmentation des pays fondé sur l'apprentissage non supervisé, permettant d'identifier les profils de vulnérabilité et d'orienter l'allocation de l'aide humanitaire de HELP International.

Construire un modèle de segmentation de pays basé sur des techniques de Machine Learning non supervisé afin d'aider à l'identification des profils de vulnérabilité humanitaire.

Objectifs spécifiques

Le projet vise à :

- enrichir la base initiale fournie dans le cadre académique ;
- construire des variables pertinentes pour l'analyse ;
- identifier des clusters homogènes de pays et interpréter les profils obtenus ;
- concevoir un tableau de bord interactif d'aide à la décision.

5. PÉRIMÈTRE DU PROJET

Inclus dans le périmètre

- collecte et fusion des données ;
- enrichissement de la base initiale ;
- analyse exploratoire des données ;
- réduction de dimension ;
- clustering de pays ;
- interprétation des clusters ;
- visualisation interactive ;
- documentation technique.

Hors périmètre

- prévision économique ;
- causalité statistique ;
- allocation budgétaire réelle ;
- recommandations géopolitiques ;
- modélisation prédictive supervisée ;
- simulation opérationnelle terrain.

6. APPROCHE MÉTHODOLOGIQUE

Vue d'ensemble du pipeline

Le projet s'organise en cinq phases séquentielles :

Phase 1 — Collecte et fusion des données
Agrégation du dataset principal Kaggle avec des bases complémentaires : indicateurs WDI de la Banque Mondiale, données sanitaires OMS, et Fragile States Index 2015. L'année de référence retenue pour la fusion est 2014, sélectionnée selon le critère de complétude maximale (taux de valeurs non manquantes) calculé variable par variable sur la période 2009–2014.

Phase 2 — Harmonisation et prétraitement
Standardisation des noms de pays (mapping ISO), imputation des valeurs manquantes par KNN, transformation logarithmique des variables à forte asymétrie ($|\text{skewness}| > 1$), suppression des redondances (income/gdpp en faveur de gdpp, coefficient de variation supérieur).

Phase 3 — Analyse exploratoire (EDA).

Phase 4 — Modélisation par clustering
Trois algorithmes sont testés : KMeans (algorithme retenu), Classification Ascendante Hiérarchique (validation topologique par dendrogramme Ward), et DBSCAN (utilisé comme diagnostic de densité). La sélection du nombre de clusters k repose sur quatre métriques croisées : inertie, silhouette, indice Calinski-Harabasz et indice Davies-Bouldin.


Phase 5 — Visualisation et dashboard

Ce choix est fondamental et mérite une justification explicite.

Un algorithme de classification supervisée (Random Forest, SVM, réseau de neurones) apprend à reproduire des étiquettes préexistantes. Or, aucune institution internationale — ni l'ONU, ni la Banque Mondiale, ni l'OCDE — ne dispose d'une taxonomie universellement acceptée des pays selon leur niveau de besoin humanitaire. Créer des étiquettes manuellement introduirait un biais normatif inacceptable : qui décide, selon quels critères, et avec quelle légitimité ?

Le clustering non supervisé ne présuppose aucune étiquette. L'algorithme explore la géométrie naturelle des données et identifie des groupes de pays mathématiquement similaires. Le résultat est émergent : ce sont les données elles-mêmes qui définissent les groupes, éliminant le biais du concepteur. Les groupes découverts reflètent des réalités structurelles objectives, communicables et défendables devant tout auditoire, y compris des comités de donateurs.

Pourquoi le clustering et non la classification ?



7. LIVRABLES

Le projet comprend les livrables suivants :

Notebooks d'analyse

- notebook de fusion et préparation des données ;
- notebook EDA — base principale ;
- notebook EDA — base enrichie ;
- notebook de modélisation et comparaison des clusters.
- notebook — interprétation

Documentation

- README du projet ;
- dictionnaire des variables ;
- Note de cadrage
- note technique ;
- note de cadrage.

Restitution

- dashboard interactif ;
- support de présentation.

8. LIMITES ET PRÉCAUTIONS

Plusieurs limites doivent être prises en compte dans l'interprétation des résultats.

Qualité et ancienneté des données

Le dataset principal (Kaggle, Country-data) agrège des données dont les millésimes sont hétérogènes, vraisemblablement compris entre 2009 et 2012 selon les variables. Cette ancienneté constitue une limite structurelle : les situations de pays tels que l'Ukraine, Gaza ou le Sahel, transformées depuis 2020, ne sont pas reflétées dans le modèle.

Hétérogénéité des sources

Les bases fusionnées (WDI, OMS, FSI) ont des méthodologies de collecte, des couvertures géographiques et des périodicités différentes. Malgré la sélection de 2014 comme année de référence commune, des incohérences résiduelles ne peuvent être totalement exclues.

Corrélation ≠ causalité

Les clusters identifiés décrivent des cooccurrences statistiques entre indicateurs. Ils ne permettent pas d'établir de relations causales entre les variables. Un pays classé en « priorité humanitaire » ne l'est pas nécessairement pour les raisons suggérées par le profil moyen de son cluster.

Biais de couverture géographique

Environ dix petits pays ne figurent pas dans le fond de carte Natural Earth utilisé pour les visualisations cartographiques, et apparaissent comme « non couverts ». Ce défaut est documenté et sans incidence sur les résultats analytiques.

Portée décisionnelle Ce projet est un outil d'aide à la décision. Il ne se substitue pas au jugement opérationnel des équipes terrain de HELP, qui disposent d'informations contextuelles inaccessibles aux données quantitatives.

Sources mobilisées

Les principales sources utilisées sont :

- Dataset HELP International (Kaggle, 2017) ;
- Banque Mondiale — World Development Indicators ;
- Organisation Mondiale de la Santé (OMS) ;
- Fragile States Index ;
- Rapports HELP.NGO ;
- FAO ;
- WFP ;
- INFORM Risk Index.




HELP

Perspectives

Plusieurs perspectives d'amélioration peuvent être envisagées :

- intégration de séries temporelles ;
- ajout de données climatiques ;
- modélisation prédictive ;
- automatisation de scénarios budgétaires ;
- intégration d'indicateurs géospatiaux ;
- analyse dynamique des crises.



Conclusion

Ce projet illustre le potentiel du Machine Learning comme outil d'aide à la décision dans le domaine humanitaire. En combinant plusieurs sources de données internationales et des techniques de clustering, l'équipe SigmaPulse propose une approche analytique visant à objectiver la compréhension des vulnérabilités structurelles des pays.

Au-delà de l'exercice académique, cette démarche met en évidence l'importance croissante des approches data-driven dans les stratégies contemporaines d'allocation des ressources humanitaires.