

NOTES TECHNIQUES

Clustering de pays pour l'optimisation de l'aide humanitaire

Rédigé par l'équipe :
SigmaPulse



Pour l'ONG :
Help International



QUI SOMMES-NOUS ?

Ce travail a été réalisé dans un cadre académique par l'équipe SigmaPulse, dont la démarche vise à combiner la précision mathématique (σ) et l'analyse des dynamiques d'urgence humanitaire (Pulse) afin de construire une approche d'aide à la décision fondée sur les données.

Dans un contexte mondial marqué par la multiplication des crises sanitaires, économiques, climatiques et sécuritaires, l'identification des pays prioritaires constitue un enjeu stratégique majeur pour les organisations humanitaires internationales. Le projet s'inscrit dans une collaboration académique inspirée du contexte opérationnel de l'ONG HELP International, confrontée à une contrainte budgétaire fictive de 10 millions de dollars destinée à soutenir les pays les plus vulnérables.

Notre ambition est d'exploiter les méthodes de Machine Learning non supervisé afin d'identifier des groupes homogènes de pays selon leurs vulnérabilités économiques, sanitaires, sociales et sécuritaires, dans une logique d'allocation plus rigoureuse, transparente et explicable des ressources humanitaires.

« L'aide humanitaire du futur ne peut plus reposer sur des intuitions géopolitiques ou des approximations décisionnelles. Avec une enveloppe limitée de 10 millions de dollars, chaque erreur de ciblage se traduit par des milliers de vies potentiellement non assistées. Notre ambition est d'exploiter le Machine Learning pour transformer des indicateurs macroéconomiques et sociaux complexes en une allocation de ressources rigoureuse, transparente et fondée sur les données. »

— ÉQUIPE SIGMAPULSE

INTRODUCTION

Dans le cadre du projet SigmaPulse, nous avons développé une chaîne complète de traitement de données visant à structurer, nettoyer et modéliser un ensemble d'indicateurs socio-économiques et humanitaires couvrant 167 pays. L'objectif est de construire une base analytique robuste permettant l'application d'algorithmes de clustering non supervisé afin d'identifier des groupes homogènes de pays en termes de développement, de vulnérabilité et de stabilité. Ce pipeline s'inscrit dans une logique d'aide à la décision data-driven pour l'ONG HELP International, en cohérence avec les standards de l'Organisation des Nations Unies, de la World Health Organization et de la Banque mondiale.



SOURCES DE DONNÉES

Source	Organisme	Variables	Période
World Development Indicators (WDI)	Banque mondiale	Santé, économie	~2009–2015
WHO Global Health Observatory	WHO	Espérance de vie, maladies	~2010–2016
Fragile States Index (FSI 2015)	Fund for Peace	Sécurité, instabilité	2015
MPI (Multidimensional Poverty Index)	OPHI / UNDP	Pauvreté multidimensionnelle	~2010–2014
FAO / WFP	ONU	Nutrition, sous-alimentation	~2010–2016



ARCHITECTURE DES DONNÉES

Le système repose sur trois couches :

- **Base principale : Country-data (167 pays, variables socio-économiques)**
- **Bases enrichies : o santé (WHO / WDI) o social (MPI, éducation, pauvreté) o sécurité (FSI 2015)**
- **Clé de fusion : code ISO Alpha-3 standardisé**

L'harmonisation des pays a été réalisée via normalisation ISO et correction manuelle des incohérences multi sources.



PRÉTRAITEMENT DES DONNÉES

Nettoyage et standardisation

- Uniformisation des noms de pays
- Normalisation des formats numériques
- Suppression des doublons

Gestion des valeurs manquantes

Trois mécanismes combinés :

- Imputation temporelle (proximité 2010–2016)
- Imputation statistique (KNN / Iterative Imputer)
- Analyse du mécanisme de manque (MCAR / MAR / MNAR)

Les données manquantes sont conservées lorsque leur absence est structurelle (ex : fragilité institutionnelle).

Valeurs aberrantes

Les outliers n'ont pas été supprimés.

Justification :

Dans un contexte mondial, les extrêmes représentent des réalités structurelles (fragilité extrême vs développement avancé) et non des erreurs statistiques.



FEATURE ENGINEERING

LES TRANSFORMATIONS
SUIVANTES ONT ÉTÉ
APPLIQUÉES :

- TRANSFORMATION LOGARITHMIQUE POUR RÉDUIRE LES ASYMÉTRIES
- TRAITEMENT SPÉCIFIQUE DE L'INFLATION :
 - TRANSFORMATION SIGNÉE : $\text{SIGN}(X) \times \text{LOG}(1 + |X|)$
- STANDARDISATION DES VARIABLES (ROBUSTSCALER)
- RÉDUCTION DE REDONDANCE ENTRE VARIABLES CORRÉLÉES

ANALYSE EXPLORATOIRE

LES ANALYSES ONT INCLUS :

- DISTRIBUTIONS UNIVARIÉES
- MATRICES DE CORRÉLATION
- ÉTUDE DES SKEWNESS ET KURTOSIS
- ANALYSE GÉOGRAPHIQUE DES INDICATEURS
- ACP (ANALYSE EN COMPOSANTES PRINCIPALES)

L'ACP A PERMIS :

- RÉDUCTION DIMENSIONNELLE
- VISUALISATION DES STRUCTURES GLOBALES
- IDENTIFICATION D'AXES "RICHESSSE VS PAUVRETÉ" ET "STABILITÉ VS CRISE"


Méthodologie de clustering

Algorithmes testés

K-Means++ (principal)

Clustering hiérarchique
(Ward)

DBSCAN (diagnostic)



Justification :

- Meilleure stabilité
- Interprétabilité élevée
- Performance sur données normalisées

Critères d'évaluation

- Silhouette score
- Davies-Bouldin Index
- Calinski-Harabasz Index
- Méthode du coude (inertie)

RÉSULTATS

DATASET CLASSIQUE

- 3 CLUSTERS :
 1. PAYS DÉVELOPPÉS
 2. PAYS INTERMÉDIAIRES
 3. PAYS PRIORITAIRES

DATASET ENRICHİ

- 4 CLUSTERS :
 1. PAYS DÉVELOPPÉS STABLES
 2. PAYS ÉMERGENTS
 3. CRISE SANITAIRE (VIH)
 4. FRAGILITÉ / CONFLITS

INTERPRÉTABILITÉ

LES CLUSTERS SONT
INTERPRÉTÉS À PARTIR DE :

- CONTRIBUTIONS DES
VARIABLES
- ANALYSE DES CENTROİDES
- SHAP (IMPORTANCE LOCALE ET
GLOBALE)
- PROFİLS SOCİO-ÉCONOMİQUES
TYPES

DASHBOARD

Architecture prévue :

- Streamlit (interface principale)
 - Onglets :
 - o About (équipe SigmaPulse)
 - o Clusters interactifs
 - o Analyse pays
 - o Comparaison modèles
 - o Liens utiles

Visualisations :

- cartes mondiales
- barplots comparatifs
- radar charts par cluster
- analyse des variables clés





LIMITES TECHNIQUES

- **HÉTÉROGÉNÉITÉ
TEMPORELLE DES
DONNÉES**
- **ABSENCE DE
CAUSALITÉ
(CORRÉLATION
UNIQUEMENT)**
- **BIAIS DE
DISPONIBILITÉ DES
DONNÉES**
- **QUALITÉ VARIABLE
SELON LES PAYS**

RECOMMANDATIONS

- **MISE À JOUR
ANNUELLE DES BASES
(WDI / WHO)**
- **INTÉGRATION DE
DONNÉES DYNAMIQUES
(TEMPS RÉEL)**
- **VALIDATION AVEC
EXPERTS
HUMANITAIRES
TERRAIN**
- **ENRICHISSEMENT PAR
DONNÉES
GÉOSPATIALES**





CONCLUSION TECHNIQUE

Le pipeline SigmaPulse démontre qu'une approche data-driven permet de structurer objectivement la diversité mondiale en groupes homogènes exploitables pour l'aide humanitaire. L'intégration de données enrichies améliore significativement la granularité des profils de vulnérabilité et permet une allocation plus fine et plus équitable des ressources.

RÉFÉRENCES INSTITUTIONNELLES

- Organisation des Nations Unies
- World Health Organization
- Banque mondiale
- United Nations Development Programme
- Food and Agriculture Organization
- World Food Programme